

研究报告 / Research Report（深度自包含对照稿）

主 HTML（自包含 Base64 图 + 内联 CSS，无 CDN）：`docs/paper/report.html`（根目录 `report.html` 为逐字副本）

PDF：`docs/paper/report.pdf`（Chrome headless；HTML 为规范源）

手稿对照：`docs/paper/manuscript.md`

数值基线：仅来自 `outputs/` 与 `models/nyc_smoke/` 的 live 产物；缺则标 待补充

GitHub（已公开，勿重复 create）：<https://github.com/Coucou2016/pluvial-flood-risk-DGGS-H3>

ChatGPT 公开 URL 索引：`artifacts/chatgpt_review_index.md`（blob + raw）；短粘贴包 `artifacts/chatgpt_paste_github_urls_R6_R10.md`；R6–R10 正文 `artifacts/chatgpt_paste_R6.md–R10.md`（另保留 R1–R5）。**Paper/report 边界（R6）**：手稿 `manuscript.md` 已剥离本地路径与 Cursor/ChatGPT 过程；本报告保留路径、复现与来龙去脉。验收：`artifacts/acceptance_R6_R10.md`。

术语总表 Terminology ledger（首次出现均给出括号释义）

术语 Term	括号释义 / Canonical meaning
Pluvial flood（城市内涝 / 雨洪）	短时强降雨超过排水与入渗能力导致的地表积水；不同于潮汐/风暴潮主导的 coastal inundation（沿海淹没）
H3（Uber Hexagonal DGGS）	Discrete Global Grid System（离散全球网格系统）中的六边形索引，支持父子分辨率嵌套
DGGS（离散全球网格）	把地球表面剖分为可索引单元的规则网格框架
Open labels（开放标签）	DEP 雨洪多边形、311 积水点、USGS Ida HWM 等公开图层；不是保险公司 PFib
PFib（building-level Pluvial Flood Index）	7Analytics / Svelling 等所用建筑级雨洪指数（保险损害驱动）；本项目不使用

PFI_h(c,r)	模型在降雨条件 $\backslash(r)$ 下对六边形单元 $\backslash(c)$ 的洪水概率/指数预测；不是特征重要性，也不是 PFIb（注意：Svellingen 等也用 PFI_h 表示其 H3 聚合后的 PFIb；本项目的 PFI_h(c,r) 是独立定义，二者符号同名但语义不同）
Spatial H3-block CV（空间 H3 块交叉验证）	按粗分辨率 H3 父块分组的 GroupKFold，整块留出，降低地理泄漏（spatial leakage）
Random split（随机划分）	近似 i.i.d. 划分；本报告仅作诊断，不得替代空间 CV
Jaccard ladder（Jaccard 阶梯）	细分辨率热点集合与父级聚合热点的集合相似度，随分辨率与聚合方式变化
MAUP（可变面元问题）	Modifiable Areal Unit Problem：分区尺度/边界改变可改变统计结论
Adaptive H3（自适应 H3）	用训练后分数筛选高风险父单元，再加密到细分辨率，以降低均匀细网格成本
LM smoke（Lower Manhattan smoke）	下曼哈顿包围盒上的开放数据烟雾测试（n_cells=141）， $\neq$ citywide smoke
assembly_mode=opendata	训练表由观测开放图层组装（非 fixture 合成表）
fixture / synthetic demo	管道 QA 用合成数据； $\neq$ science
I2（观测事件降雨）	计划接入 gauge/radar 事件降雨；当前仍阻塞，仅有合成常数 event_raster
Negative control（负对照）	FEMA Sandy 沿海淹没叠置检查；永不作为训练标签
SciencePlots	matplotlib 学术样式插件；本报告图使用 Times New Roman（TNR）
Trivial / majority baseline（平凡基线 / 多数类基线）	不做学习的“闭眼”预测（如恒判正类）；用于对照模型是否真的学到判别力

1. 摘要 Abstract

本报告是仓库 **live Lower Manhattan open-data smoke** 的教师向（teacher-like）过程说明：不只贴图，而是交代每张表/图的来龙去脉、如何读、意义、可下的结论、不可下的结论。

在 H3 分辨率 R9 上组装 **n_cells = 141** 个六边形单元，assembly_mode=opendata。主（分块评价）指标为 **spatial H3-block CV**（空间 H3 块交叉验证）：准确率均值 **0.783756 ± 0.069280** ，F1 均值 **0.865748**（来源：models/nyc_smoke/run_metadata.json，created_utc=2026-08-16T06:36:48Z）。关键诚实修正（2026-08-17）：留出样本正类占比 **80.1%**，恒判正的多数类平凡基线在同样折上可达 accuracy **0.808**、F1 **0.893**，高于模型的 0.784 / 0.866——故这两个数不得被称为“分类技能”

（来源：outputs/classification_baselines.json）。尺度损失用开放标签 **Jaccard ladder** 诊断：细 R10→粗 R8 的 **mean** 聚合 Jaccard = **0.1667**（不得写成“复现了 Svelling 的 0.14”）。自适应相对均匀细网格（R11）单元数比 **adaptive_cell_count_ratio** ≈ 0.569 。

诚实缺口（待补充）：(1) I2 观测事件降雨仍阻塞，rainfall_source=event_raster 为合成常数钩子；(2) outputs/pfi_h_scenarios.csv 四情景（25/40/75/100 mm/h）下，单元内 **PFI_h** 极差 = 0，情景均值同为 ≈ 0.802888 ，故不宣称已观察到降雨条件判别力；(3) LM $\neq$ citywide；(4) ChatGPT 浏览器 MCP 本会话不可用，顾问 web-search 回复待人工粘贴 brief。

2. 背景 Background（问题从何而来）

2.1 城市 pluvial flood 为什么难

短时强降雨可在数小时内淹没街道与低洼地。城市评估需要：(i) 可扩展的空间表示；(ii) 新观测到达时可更新；(iii) 评价时不因邻近样本泄漏而虚高分。H3 提供嵌套六边形，便于多分辨率汇总与邻域查询。

2.2 对照文献（不是复制目标）

Svelling et al. (2026), *International Journal of Disaster Risk Reduction* (DOI: <https://doi.org/10.1016/j.ijdr.2026.106091>) 把机器学习得到的建筑级 **PFib** 聚合到 H3，报告空间查询效率约提升 98%，并指出细（约 R13）与粗（约 R10）热点 Jaccard ≈ 0.14 。该文是 **H3 + pluvial** 最近的强对照，但它依赖专有/保险损害驱动的 **PFib**，且主叙事是聚合与沟通，不是开放标签下的空间诚实学习协议。

本项目的问题 accordingly 改写为：

在无法获取 **PFib** 的辖区，能否用开放多源标签在 H3 上完成：空间块评价、尺度损失诊断、由训练分驱动的自适应加密，并给出明确的非 **PFib** 的 **PFI_h(c,r)** 定义？

2.3 写作架构（本报告与手稿共同遵守）

- 主结构：IJDRR / 应用灾害风险期刊骨架（Intro → Related → Data → Methods → Results → Discussion → Conclusions）。
- 主张纪律：nature-writing / Nature claim discipline——证据 → 边界；动词用 *show / indicate / suggest*；禁止把 LM smoke 写成全市产品。
- 文献顾问：目标会话 <https://chatgpt.com/c/6a8086e4-3a30-83ea-960b-cde100e0f3b2>；公开仓库 URL 索引：artifacts/chatgpt_review_index.md（raw.githubusercontent.com 供 ChatGPT 读

取）。`cursor-ide-browser` 再次失败（No browser tab available / view 瞬时消失）；执行侧独立 WebSearch 继续成熟化手稿（含 Sun/Hu spatial CV 作者校正）与 `artifacts/literature_architecture_conclusions.md`。

3. 数据与方法 Data & Methods

3.1 研究区（必须反复强调边界）

配置中的 **Lower Manhattan bbox**（约 74.02–73.97°W，40.70–40.76°N；以 `configs/nyc.yaml` / `DOWNLOAD_MANIFEST.json` 为准）。这是 **pilot smoke extent**，不是纽约全市。

3.2 Live 图层（2026-08-15 工作区下载；非虚构）

图层	角色
USGS 3DEP DEM 子集	高程 / 坡度等地形特征
DEP stormwater flood polygons	开放雨洪标签之一
Building footprints	建筑密度等
USGS Ida high-water marks	点状开放标签
311 flooding points	点状开放标签（报告偏差风险）
FEMA Sandy inundation	仅负对照，永不训练
NLCD impervious	不透水比例
NHDPlus HR	<code>dist_stream_m</code> 作为 distance-to-water 代理（潮汐岸线语境下需谨慎解释）
FloodNet	默认关闭 / stub; opt-in
<code>event_rainfall.tif</code>	合成常数 Ida-like 钩子，不是 radar/gauge

Provenance: `assembly_mode=opendata`；降雨侧仍可能报告 `rainfall_source=event_raster`。

3.3 H3 分辨率角色

用途	分辨率	说明
----	-----	----

训练主表	R9	n_cells=141
Jaccard 细网格	R10	热点分位 0.9
Jaccard 父级	R9 / R8	mean / max / p90 上卷
自适应加密	R11	高分父单元细化

3.4 模型与评价协议

- 主学习器： 梯度提升分类器 + 连续风险回归器。
- 基线： L2 逻辑/线性，以及高程–不透水–坡度类规则（管道内；本报告以空间 CV 为主）。
- 主指标： spatial H3-block GroupKFold（5 folds, 7 blocks）；并报告类别占比与多数类平凡基线（outputs/classification_baselines.json）。
- 诊断： random split val accuracy ≈ 0.690 —— 不得在摘要中替代空间 CV。
- 软件元数据： h3 4.4.2； sklearn 1.8.0； random_seed=42； framework pluvial-flood-risk-dggs-h3 v0.1.0。

3.5 绑定定义：PFI_h(c,r)

\[

$$\mathrm{PFI}_h(c,r)=\widehat{P}(Y_c=1\mid X_{c,r})$$

\]

静态特征 $\backslash(X_c\backslash)$ 固定，降雨条件 $\backslash(r\backslash)$ 在命名情景间变化。这是 **model output**（模型输出），不是 SHAP/permutation importance，也不是 PFI_b。当前 smoke 的情景表尚未显示非零响应（见 §5.6）。




图 1 · Figure 1 — 开放标签 H3 雨洪学习协议的概念 workflow（SciencePlots + Times New Roman）。
如何读：从左到右四列——(1) 开放多源输入；(2) H3 组装（R9 + provenance 标签）；(3) 学习与分块评价（GBM + H3 块 GroupKFold 空间 CV + 多数类平凡基线）；(4) 诊断与输出（PFI_{h(c,r)}、Jaccard 阶梯、自适应加密、Sandy 负对照）。
意义：一张图讲清整条协议与「证据—边界」纪律，对应手稿 Methods。
结论：PFI_{h(c,r)} 是模型输出，不是特征重要性，也不是 PFIb；证据仅限 Lower Manhattan 试点，非全市。

来龙去脉：这是论文的 Figure 1 概念工作流图（SciencePlots + Times New Roman），由 src/pluvial_flood_risk/figures.py 的 plot_workflow_schematic 生成，无数据依赖，对应手稿 Methods 的四个阶段。

如何读：从左到右四列——(1) 开放多源输入（开放标签 + 静态特征 + 降雨条件 *r* + FEMA Sandy 负对照）；(2) H3 组装（R9，带 provenance 标签）；(3) 学习与分块评价（梯度提升 + H3 块 GroupKFold 空间 CV + 多数类平凡基线 + 逻辑/积水规则基线）；(4) 诊断与输出（PFI_{h(c,r)}、Jaccard 尺度损失阶梯、自适应加密、Sandy 负对照检查）。

意义：一张图讲清整条协议与「证据—边界」纪律，帮助审稿人快速定位每一步对应的结果小节。

结论： $PFI_h(c,r)$ 是模型输出，不是特征重要性，也不是 PFI_b ；证据仅限 Lower Manhattan 开放数据试点，非全市。

4. 过程 Process（怎么跑到这些图）

1. 下载/校验 `data/raw/nyc/`，写入 `DOWNLOAD_MANIFEST.json / DATA_SOURCES.md`。
 2. `build_nyc_h3.py --no-fixtures` → `data/processed/nyc_h3_cells.parquet`（opendata）。
 3. `pluvial-nyc-smoke` → `models/nyc_smoke/*`、`outputs/*`（空间 CV、Jaccard、自适应、情景、负对照）。
 4. SciencePlots + TNR 重绘三图到 `docs/paper/figures/`（并同步 `artifacts/figures/`）。
 5. `scripts/build_paper_report_html.py` → 自包含 `report.html`（Base64 图、内联 CSS）。
 6. `Chrome headless --print-to-pdf` → `report.pdf`（若失败，以 HTML 为准并记入 `acceptance`）。
- 12 阻塞说明：** 观测事件降雨 `ingest` 未完成；本报告继续基于 `live outputs` 写作，并在局限中诚实标注。

5. 结果 Results（只引用真实产物）

表 1 · 空间 CV 汇总（主分块评价表）

来源： `models/nyc_smoke/run_metadata.json`（模型折均） + `outputs/classification_baselines.json`（平凡基线，2026-08-17 固化）

Metric	Value
n_cells	141
spatial_cv_n_folds / n_blocks	5 / 7
accuracy mean ± std	0.783756 ± 0.069280
F1 mean	0.865748
R ² mean ± std	0.030333 ± 0.342841
MAE mean	0.332182
random_split_val_accuracy（诊断）	0.689655

留出正类占比（prevalence）	0.8014
多数类（恒判正）基线 accuracy	0.808
多数类（恒判正）基线 F1	0.893
模型是否超过多数类基线 acc / f1	否 / 否

来龙去脉： smoke 跑完后，训练脚本把 GroupKFold 各折平均写入 metadata；随后 scripts/compute_classification_baselines.py 读取 spatial_cv_folds.csv，对每折计算“全部判正”“全部判负”两种平凡基线并写入 outputs/。这是论文/报告里唯一优先引用的评价汇总，且必须连同类别占比与多数类基线一起引用。

如何读： 先看正类占比（0.8014，即 80% 留出单元为正），再看多数类基线（恒判正 acc 0.808 / F1 0.893），最后才看模型分数（0.784 / 0.866）。模型分数低于多数类基线，说明在本试点上分类器并未展现出超过“闭眼判洪”的判别力；R² 接近 0 也说明连续风险回归几乎无解释力。随机划分准确率略低/不同，仅提示“换协议分数会变”，不能当主结果。

意义： 空间块留出让评价设计更诚实，但它本身不产生技能证据；在类别严重失衡时，accuracy/F1 必须与平凡基线对照，否则会被虚高。

结论（允许）： LM smoke 上协议可跑通（能训练、能分块评价、能出表）。

结论（禁止）： 全市技能；“模型有分类判别力”（本轮未超过多数类基线）；用随机划分替换空间 CV；“已解决事件响应预报”。

表 2·逐折明细

来源： models/nyc_smoke/spatial_cv_folds.csv

fold	n_train	n_test	accuracy	f1	r2	mae
0	92	49	0.755	0.850	-0.440	0.409
1	116	25	0.760	0.850	-0.089	0.369
2	119	22	0.773	0.872	-0.021	0.376
3	120	21	0.714	0.813	0.082	0.307
4	117	24	0.917	0.944	0.620	0.199

来龙去脉： 每个 fold 留出 1-2 个粗 H3 父块；测试块 ID 列在 CSV 的 test_block_ids。

如何读： Fold4 准确率 0.917 明显高于其他折——这正是必须同时报告 std 的原因：块大小与正负类比例不均时，单折会跳动。

意义： 展示评价协议的折间不稳定性，而不是“挑最好一折”。

结论： 均值有效，但外部效度仍受小样本与块不均限制。




图 2 · Figure 2 — 空间 H3 块 CV 各折 Accuracy 与 F1（SciencePlots + Times New Roman）。

如何读： 横轴为折号，纵轴为 0–1 分数；成对柱表示同一折的 Accuracy/F1。

意义： 展示评价协议的折间稳定性，而非单一乐观分数。

结论： 多数折 Accuracy≈0.71–0.77，Fold4 更高；与表 1 均值一致。样本仍是 Lower Manhattan smoke。

来龙去脉： 由 spatial_cv_folds.csv 经 src/pluvial_flood_risk/figures.py（SciencePlots + TNR）绘制 Accuracy/F1 成对柱。

如何读： 横轴 fold_id；纵轴 0–1；每折两柱。

意义： 把表 2 变成可一眼比较的稳定性图。

结论： 多数折 Accuracy≈0.71–0.77，Fold4 抬高均值；与表 1 一致。仍是 LM smoke。

表 3 · Jaccard 尺度损失阶梯

来源： outputs/jaccard_by_resolution.csv（fine_res=10，hotspot_quantile=0.9）

coarse	agg	jaccard	f1
8	mean	0.1667	0.2857

8	max	1.0000	1.0000
8	p90	1.0000	1.0000
9	mean	0.9767	0.9882
9	max	1.0000	1.0000
9	p90	0.9767	0.9882

附：细网格 $n_{\text{fine}}=991$ ，热点 $n_{\text{hotspot_fine}}=571$ （阈值）。

来龙去脉：在细 R10 上取高风险热点集合，再按父单元用 mean/max/p90 聚合后与粗网格热点比 Jaccard/F1。目的是诊断 **MAUP / scale-loss**，不是复现 PF1b 文献数字。

如何读：关注 **mean@R8=0.1667**：粗尺度平均抹平了细热点；max/p90 接近 1 是因为极值保留机制，不是“粗网格完美”。

意义：说明“沟通粗网格”与“安全关键细热点”不可混为一谈——这与 Svelling 的尺度权衡叙事概念对话，但标签栈不同。

结论（允许）：开放标签下，mean 上卷到 R8 会严重改变热点集合。

结论（禁止）：“我们得到了与 Svelling 相同的 Jaccard 0.14”；把 max/p90=1 写成模型完美。




图 3 · Figure 3 — 开放标签热点 Jaccard/F1 随粗分辨率变化（SciencePlots + TNR）。

如何读：左 Jaccard、右 F1；线型区分 mean/max/p90 上卷。

意义：量化 MAUP/尺度损失：决策尺度变粗时，热点集合可能面目全非。

结论：mean@R8 损失最大；不得与 PF1b 文献的 0.14 直接等同。

来龙去脉：同 CSV 的 SciencePlots 折线（左 Jaccard、右 F1；线型区分 agg）。

如何读： 随 coarse_res 变粗，看 mean 线是否下降。

意义： 可视化尺度损失。

结论： mean 在 R8 损失最大；禁止与 PFib 的 0.14 数值等同。

表 4 · 自适应 vs 固定 / 均匀细网格

来源： outputs/adaptive_vs_fixed_ablation.csv

Field	Value
score_col	PFI_h
n_fixed_coarse (R9)	141
n_adaptive_mixed	3933
n_uniform_fine (R11)	6909
adaptive_cell_count_ratio (adaptive/uniform)	0.569257
parents_refined	79
score_quantile	0.8
coarse→fine	9→11

来龙去脉： 训练后用 PFI_h 筛高分父单元，再加密到 R11，形成混合分辨率网格；与“全部留在 R9”和“全部升到 R11”对比单元数。

如何读： 141 → 3933 → 6909；比率 0.569 表示自适应约为均匀细网格 **57%** 的单元数。

意义： 在计算预算与局部细化之间的工程折中；分数来源写明为 trained PFI_h。

结论（允许）： 本 smoke 设定下自适应降低均匀细网格单元数约四成多。

结论（禁止）： 全市算力节省；自适应已提高泛化技能（本表是单元数消融，不是技能提升表）。




图 4 · **Figure 4** — 固定粗网格 / 自适应混合 / 均匀细网格单元数。
如何读：三柱分别为 R9 全保留、自适应混合、R11 均匀。
意义：展示自适应在计算预算与局部细化之间的折中。
结论：自适应单元数介于粗与均匀细之间；比率≈0.57。非全市成本声明。

来龙去脉： 三柱条形图对应表 4 三个单元数。

如何读： 中间柱应介于左右之间。

意义： 一眼看到成本折中。

结论： 与表 4 一致；非全市声明。

表 5 · **Sandy** 负对照

来源： outputs/negative_control.json

Field	Value
n_cells	141
n_coastal / n_pluvial / n_both	31 / 71 / 23
n_coastal_only / n_pluvial_only	8 / 48

n_neither	62
frac_coastal_only	0.0567
pluvial_minus_coastal_mean_score	0.1198
score_col	flood_risk
assembly_mode	opendata

来龙去脉：把 FEMA Sandy 沿海淹没与开放 pluvial 标签叠在同一批 H3 单元上，检查空间是否完全重合。

如何读：n_both=23 说明有重叠；n_coastal_only=8 说明存在“只沿海、不落进 pluvial 标签”的单元；均值分差 ≈0.12。

意义：负对照提醒模型不要把 coastal 过程误当成 pluvial 训练信号。

结论（允许）：标签空间不完全重合；差分提示分离检查有信号。

结论（禁止）：已验证因果分离；可用 Sandy 当训练标签。

5.6 PFI_h 降雨情景（诚实缺口·待补充）

来源：outputs/pfi_h_scenarios.csv（564 行 = 141 单元 × 4 情景）

scenario	rainfall_mm_h	mean PFI_h
moderate	25	0.802888
heavy	40	0.802888
ida_like	75	0.802888
extreme	100	0.802888

核验：按 h3_index 分组，max(PFI_h)-min(PFI_h) 的全局最大值为 **0.0**。

来龙去脉（根因已确诊，**2026-08-17**）：情景循环本身正确——只改 rainfall_mm_h 再预测，产物里 4 个情景的 rainfall_mm_h 也确实分别是 25/40/75/100。平坦的真正原因是训练阶段降雨是常数：训练表 data/processed/nyc_h3_cells.parquet 的 141 个单元 rainfall_mm_h 全部为 **75.0**（rainfall_source=event_raster 的合成常数钩子），因此 rainfall_mm_h 在训练特征矩阵中方差为 0；GradientBoostingClassifier 对该列的特征重要性为 **0.0**（models/nyc_smoke/classifier.joblib）。模型从未见过降雨变化，自然无法对情景做出响应。

结论： 定义保留；经验判别力本轮不成立，且成因不是 bug 而是“训练降雨恒为常数”。要得到非零响应，必须先引入 I2 观测事件降雨（多强度、非合成 provenance），再重训；在此之前禁止在摘要写“情景响应已验证”。

5.7 扩展 bbox 主表（manhattan_expanded, n=956）

来源： outputs/expanded_primary_table.json、models/nyc_expanded/spatial_cv_folds.csv、outputs/classification_baselines_expanded.{json,csv}；原始数据在 data/raw/nyc_expanded/（DOWNLOAD_MANIFEST.json 可溯源）。

来龙去脉： §5.1 的 n=141 表只覆盖 Lower Manhattan 极小窗口，正类占比高达 80.1%，被 ChatGPT R8 评审判为“material issue”——因为 80% 的正类意味着“永远说会淹”的平凡基线就能拿到 0.808 accuracy / 0.893 F1，模型反而打不过它。为验证这是否只是“小窗口被 DEP 洪泛多边形覆盖”导致的空间伪象，本小节把同样的开放数据协议跑在更大的 manhattan_expanded 范围（[-74.03, 40.68, -73.94, 40.80]，约 0.09° × 0.12°，从曼哈顿下城向上城/中城南扩展），得到 n=956 个 R9 单元、28 个空间块。

如何读： 下表与 §5.1 表 1 同构，便于直接对照“小窗口 vs 扩展窗口”。

Metric	扩展窗口 (manhattan_expanded)	小窗口 (LM smoke)
n_cells	956	141
spatial_cv_n_blocks	28	7
spatial_cv_n_folds	5	5
正类占比（held-out）	0.479	0.801
spatial_cv_accuracy_mean ± std	0.642 ± 0.148	0.784 ± 0.069
spatial_cv_f1_mean	0.608	0.866
spatial_cv_r2_mean ± std	0.525 ± 0.112	0.030 ± 0.343
spatial_cv_mae_mean	0.112	0.332
random_split_val_accuracy（仅诊断）	0.667	0.690
always-positive（多数类）accuracy	0.479	0.808
always-positive（多数类）F1	0.648	0.893
模型是否超过多数类 accuracy	是（0.642 > 0.479）	否（0.784 < 0.808）
模型是否超过多数类 F1	否（0.608 < 0.648）	否（0.866 < 0.893）

逐折明细（models/nyc_expanded/spatial_cv_folds.csv）：

fold	n_test	正/负	accuracy	f1	r2
0	191	119 / 72	0.801	0.832	0.486
1	191	66 / 125	0.419	0.442	0.713
2	191	97 / 94	0.759	0.736	0.533
3	190	73 / 117	0.516	0.343	0.525
4	193	103 / 90	0.715	0.689	0.366

意义（为什么这个表重要）：

1. 类别失衡得到缓解。扩展窗口正类占比 47.9%，接近均衡；这证明小窗口的 80.1% 正类主要是“极小 bbox 落在 DEP 洪泛多边形内”的空间伪象，而不是模型本身的问题。
2. **accuracy** 首次超过多数类平凡基线。扩展窗口模型 0.642 的 **accuracy** 明显高于“永远说会淹”的 0.479，说明模型在更大的空间范围里确实学到了可迁移的判别信息；这与小窗口“打不过平凡基线”形成鲜明对比。
3. 连续风险 **R²** 从近零跃升到 **0.525**。小窗口 $R^2 \approx 0.030$ （近乎无用），扩展窗口 $R^2 \approx 0.525$ （中等偏强），说明连续风险回归器在更大、更均衡的样本上具有真实信号。这一点也反过来支持“小窗口 R^2 近零是样本规模/空间覆盖不足所致”的判断。
4. **F1** 仍低于多数类基线（**0.608 < 0.648**）。F1 是对正类的调和平均；在均衡设定下，“永远说会淹”仍有 $\text{recall}=1$ 、 $\text{precision}=0.479$ ， $F1 \approx 0.648$ 。模型为了提升精度而牺牲了部分 recall ，导致 F1 略低于平凡基线。因此分类判别力仍只能算“部分建立”，不能用 F1 主张“分类技能”。

结论（**honest**）：扩展窗口主表不是全市结果（仍是曼哈顿中城南+下城北的试点），但它把“小窗口因类别失衡而打不过平凡基线”这一最严重短板缓解了：模型在 **accuracy** 上超过多数类基线，连续 **R²** 显著增强。下一步仍缺：真正的 citywide 范围、ROC-AUC 等失衡感知判别指标、观测事件降雨、FloodNet 留出验证。

6. 讨论 Discussion

相对 Svelling et al. 2026，本工作的可对话差异是：

1. 开放标签而非 PFIb；
2. 空间块 **CV** 优先（符合 GeoAI spatial CV 文献对泄漏的警告）；
3. 尺度损失阶梯建在开放热点上；
4. 自适应由 trained PFI_h 驱动；

5. 语义澄清：PFI_h(c,r) ≠ importance ≠ PFib。

证据强度仅支撑“协议可跑通 + 尺度损失可见 + 单元数可降”，不支撑“全市可部署事件响应系统”。
分类判别力方面：小窗口（80% 正类）模型打不过多数类平凡基线；扩展窗口（manhattan_expanded，47.9% 正类，28 块）模型在 accuracy 上超过多数类基线（0.642 > 0.479）、连续 R² 跃升到 0.525，但 F1 仍低于平凡基线（0.608 < 0.648），故判别力只算部分建立、仍不主张“分类技能”。311 报告偏差、潮汐岸线水文代理、合成降雨、平坦情景 PFI、小样本块不均（小窗口仅 7 块分 5 折），是主要科学风险。

独立 WebSearch（本轮）再次确认：Svellingén DOI 与 Jaccard≈0.14 / ~98% 效率叙述；spatial CV / GroupKFold 是 GeoAI 诚实评价的标准关切。ChatGPT 顾问若稍后回复，只合并不冲突建议；冲突时以 locked science 为准。

7. 结论 Conclusions

- 1. 开放标签 H3+ML + 空间块 CV 已产生两个试点（LM smoke n=141、扩展窗口 n=956）的可引用元数据，以及四张 SciencePlots 主图（ workflows F1、空间 CV F2、Jaccard F3、自适应 F4）。
- 2. Jaccard 与自适应消融提供了与 PFib 文献可概念对话、但不可数值等值的证据。
- 3. PFI_h(c,r) 定义已绑定；情景响应与 I2 观测降雨为下一步（待补充）。
- 4. 分类判别力部分建立、仍未主张“分类技能”：小窗口 accuracy/F1（0.784/0.866）低于多数类平凡基线（0.808/0.893）；扩展窗口 accuracy 超过多数类基线（0.642 > 0.479）且连续 R²=0.525，但 F1（0.608）仍低于平凡基线（0.648）。失衡感知指标（ROC-AUC）待补充。
- 5. 可主张创新点见 docs/paper/innovation_and_framework.md 的 I1–I5；拒绝 PFib 复现、Jaccard 0.14 等同、LM→citywide、雷达降雨、平坦情景判别、以及“分类有技能”的表述。

8. 局限 Limitations（务必留给审稿人/老师看）

局限	状态
LM smoke n=141 ≠ citywide	锁定
扩展窗口 manhattan_expanded n=956 ≠ citywide	锁定（outputs/expanded_primary_table.json）
类别失衡（小窗口 80% 正类 → 模型未超多数类基线；扩展窗口 47.9% → accuracy 超基线、F1 未超）	锁定（outputs/classification_baselines.json / classification_baselines_expanded.json）

合成 event_raster; I2 阻塞	锁定
情景 PFI_h 单元内极差=0	锁定（待补充修复）
FloodNet 默认关闭	锁定
Oslo / fixture $\neq$ science	锁定
ROC-AUC 等失衡感知判别指标	待补充（尚未归档为 live 产物）
工作流图 F1 schematic	完成（docs/paper/figures/workflow_schematic.png, SciencePlots + TNR）
ChatGPT web-search 顾问回复	已收到 R6–R10 活体评审（2026-08-17 人工粘贴），正在合并
GitHub 远程仓库	已公开 https://github.com/Coucou2016/pluvial-flood-risk-DGGS-H3 （勿重复 gh repo create; 勿 force-push）

8.1 Paper vs report boundary (R6 audit)

Belongs in paper (manuscript.md)	Belongs in report (this file)
Academic claims, methods narrative, live numbers with honest bounds	Local paths (outputs/, models/nyc_smoke/, configs)
Figure captions without repo-relative paths	Reproducibility commands, pytest gates, ChatGPT round process
Public GitHub URL + data availability	Cursor/ChatGPT collaboration logs, paste packages
待补充 scientific gaps	来龙去脉, download dates, machine-local session notes

R6 applied: stripped advisor-chat URLs, nature-writing axes metadata, and outputs/ / models/nyc_smoke/ path literals from the manuscript body; retained those details here.

9. 产物路径清单

Artifact	Path
Report HTML	docs/paper/report.html, report.html
Report MD	docs/paper/report.md
Report PDF	docs/paper/report.pdf

Manuscript	docs/paper/manuscript.md/.html/.pdf
Figures	docs/paper/figures/*.png
Metadata	models/nyc_smoke/run_metadata.json
Classification baselines	outputs/classification_baselines.json / .csv (脚本 scripts/compute_classification_baselines.py)
Expanded-bbox primary table	outputs/expanded_primary_table.json (脚本 scripts/run_expanded_study.py)
Expanded-bbox baselines	outputs/classification_baselines_expanded.json / .csv
Expanded-bbox models/folds	models/nyc_expanded/ (run_metadata.json, spatial_cv_folds.csv)
Literature conclusions	artifacts/literature_architecture_conclusions.md
ChatGPT brief	artifacts/chatgpt_literature_brief.md
Collaboration	artifacts/chatgpt_collaboration_report.md
Acceptance	artifacts/acceptance_report_*.md

生成说明：数值均从上述 CSV/JSON 抄录或脚本聚合；若与磁盘文件冲突，以磁盘 live 文件为准。